

Reflection:

7.5. Inspect Vocabulary & Comparative

- Top 20 Term có DF cao nhất: Chủ yếu là các từ dừng (stopword) phổ biến như "the", "and", "to", "of", "in", ... Chúng xuất hiện ở hầu hết mọi văn bản trong corpus.
 - Top 20 Term có IDF cao nhất: Thường là các chuỗi số / mã định danh thuật ngữ hiếm, ...
 - Top 20 Term có TF-IDF cao nhất trong document 0: Bao gồm các từ mang thông tin chủ đề chính của nội dung vb đó.
- Also Analysis:

- Một term xuất hiện rất nhiều trong corpus có nhất thiết có TF-IDF cao không?

Không. Nếu một term xuất hiện quá phổ biến trong toàn bộ corpus, giá trị IDF của nó sẽ rất nhỏ. Theo CT TF-IDF, dù TF trong document có cao đến đâu, khi nhân với IDF ≈ 0 thì điểm TF-IDF vẫn sẽ rất thấp.

- Một term có IDF cao nhất có nhất thiết có TF-IDF cao trong mọi Document không?

Không. Một term có IDF cao đồng nghĩa là nó là một từ rất hiếm và chỉ xuất hiện trong một vài document nhất định.
 $\rightarrow TF-IDF = 0$.

9.5. Preprocessing

1. Lowercasing làm thay đổi vocab ntn?

- Lowercasing gộp các biến thể hoa/thường của cùng một từ thành 1 token duy nhất

2. Stopword removal có liên quan tới representation không?
- Không. Trong khi qu

3. Việc loại punctuation có thu làm mất thông tin gì?
- Loại bỏ dấu câu có thể làm mất các cú pháp đặc thù.

4. Pipeline nào tạo ra sparse matrix nhất?

- Pipeline A

- Do việc tạo thêm n-grams khiến kích thước bùng nổ lên tới 3, 976, 923 unique term, trong khi mỗi vb chỉ chứa 7b 295,01 tokens, dẫn đến hầu hết các ô trong ma trận đều = 0.

5. Pipeline nào cho Search tốt nhất?

- Pipeline B

- Do p B đạt sự cân bằng tốt nhất.

6. Search tốt hơn có đồng nghĩa với vocabulary nhỏ hơn không? Không. Vocab nhỏ hơn chỉ để giúp giảm chi phí bộ nhớ và ↑ tốc độ tính toán.

Part II

Analysis:

1. Vì sao document đứng đầu: vì nó chứa đồng thời nhiều từ trong query

2. Những từ nào có đóng góp nhiều vào similarity?

Đặc từ có IDF cao

3. Có lexical overlap không? Có

4. Có relevant nào bị bỏ sót không? Có

5. Failure này xuất phát từ đâu? Lexical matching

Part I:

1. Predict nào sai? Sparsity đoán sai

2. Kết quả nào bất ngờ nhất? Top 10 từ có IDF cao nhất


3. Experiment nào cung cấp evidence mạnh nhất?

Thí nghiệm part F: preprocessing

4. Failure & case ở trong nào?

Thí query "heart attack treatment" thất bại trong việc xếp hạng cao 1 tài liệu y khoa chứa cụm từ "myocardial infarction therapy"

Learning is the eye of the mind



5. Nếu xây lại search engine, em sẽ thay đổi điều gì?

Bộ p² ghép từ thể và chuyển sang dùng Dense Retrieval / Semantic Search dựa trên Word Embeddings.

6. AI đã đóng góp gì vào bt này?

Code & các part em đã ghi trong file experim và implement.